



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ НА ТЕМУ:

*«Метод обнаружения признаков генерации на
изображении с использованием нейронной сети»*

Студент ИУ7-74Б
(Группа)

(Подпись, дата)

М. А. Сальников
(И. О. Фамилия)

Руководитель ВКР

(Подпись, дата)

К. А. Майков
(И. О. Фамилия)

Нормоконтролер

(Подпись, дата)

П. П. Преподавателей
(И. О. Фамилия)

2026 г.

СОДЕРЖАНИЕ

РЕФЕРАТ	4
ОПРЕДЕЛЕНИЯ	5
ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	7
ВВЕДЕНИЕ	8
1 Аналитический раздел	9
1.1 Анализ предметной области	9
1.1.1 История возникновения поддельных изображений	9
1.1.2 Применение методов обнаружения признаков генерации на изображении	10
1.2 Анализ известных нейросетевых решений	10
1.2.1 Свёрточные нейронные сети	12
1.2.2 Капсульные нейронные сети	16
1.2.3 Трансформеры	19
1.3 Классификация рассмотренных решений	22
1.3.1 Критерии классификации	22
1.3.2 Результаты классификации	24
1.4 Сравнительный анализ рассмотренных решений	25
1.4.1 Критерии сравнения	25
1.4.2 Результаты сравнения	25
1.5 Формализация изображения	26
1.6 Формализация задачи	27
1.7 Выводы из аналитического раздела	28
2 Конструкторский раздел	29
2.1 Функциональная модель разрабатываемого метода	29
2.2 Требования к разрабатываемому методу	29
2.3 Требования к разрабатываемому программному обеспечению	30
2.4 Известные наборы необходимых размеченных данных	30
2.4.1 FaceForensics	30
2.4.2 FaceForensics++	31

2.5	Трансферное обучение нейронных сетей	32
2.6	Ансамблирование нейронных сетей	33
2.7	Архитектура разрабатываемой нейронной сети	33
2.7.1	Функциональная декомпозиция архитектуры	33
2.7.2	Формирование ансамбля нейронных сетей	34
2.7.3	Обучение разрабатываемой нейронной сети	36
2.8	Архитектура разрабатываемого программного обеспечения . . .	38
2.8.1	Функциональная декомпозиция архитектуры	38
2.8.2	Контекст проектируемой архитектуры	39
2.8.3	Компоненты проектируемой архитектуры	40
2.9	Выводы из конструкторского раздела	43
3	Технологический раздел	44
3.1	Выбор средств программной реализации	44
3.2	Результаты обучения нейронной сети	44
3.3	Демонстрация работы программного обеспечения	48
3.4	Тестирование программного обеспечения	49
3.5	Выводы из технологического раздела	50
4	Исследовательский раздел	51
4.1	Постановка исследования	51
4.2	Проведение исследования	51
4.2.1	Качество разработанного метода на наборе данных FaceForensics	51
4.2.2	Сравнение разработанного метода с рассмотренными ре- шениями	53
4.2.3	Классификация разработанного метода	54
4.3	Выводы из исследовательского раздела	55
	ЗАКЛЮЧЕНИЕ	56
	СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	62
	ПРИЛОЖЕНИЕ А	63
	ПРИЛОЖЕНИЕ Б	64

РЕФЕРАТ

Расчетно-пояснительная записка 64 с., 31 рис., 0 лист., 56 ист., 2 прил.

НЕЙРОННАЯ СЕТЬ, ОБНАРУЖЕНИЕ ПРИЗНАКОВ ГЕНЕРАЦИИ, ГЛУБОКОЕ ОБУЧЕНИЕ, КОМПЬЮТЕРНОЕ ЗРЕНИЕ, АНСАМБЛЬ МОДЕЛЕЙ, EFFICIENTNET, VISION TRANSFORMER, FACEFORENSICS.

Цель работы: разработка метода обнаружения признаков генерации на изображении с использованием нейронной сети.

В данной работе разрабатывается метод обнаружения признаков генерации на изображении с использованием нейронной сети. Проводится анализ предметной области и известных нейросетевых решений. Выполняется классификация и сравнительный анализ сверточных, капсульных нейронных сетей и трансформеров. Проектируется архитектура ансамбля нейронных сетей на основе EfficientNet и Vision Transformer. Реализуется программное обеспечение с графическим интерфейсом, и производится обучение модели на расширенном наборе данных FaceForensics++. Проводится исследование точности и устойчивости разработанного метода к сжатию изображений.

В результате работы разработан метод обнаружения признаков генерации на изображении, демонстрирующий точность 98,75% на наборе данных FaceForensics и превосходящий рассмотренные аналоги по устойчивости к шуму. Создано приложение, позволяющее загружать изображения и получать вероятностную оценку наличия признаков генерации. Выполнено тестирование программного обеспечения и подтверждена его работоспособность на реальных сценариях.

ОПРЕДЕЛЕНИЯ

В настоящей расчетно-пояснительной записке применяют следующие термины с соответствующими определениями.

Признак генерации — опирающийся на технологии машинного обучения целенаправленно созданный атрибут медиапродукта.

Поддельное изображение — изображение, содержащее направленный на формирование у целевых аудиторий фальсифицированного образа социального субъекта с целью получения выгоды или нанесения ущерба достоверно установленный признак генерации.

Искусственный нейрон — упрощенная математическая модель биологического нейрона [1].

Искусственная нейронная сеть — совокупность взаимосвязанных искусственных нейронов [2].

Слой искусственной нейронной сети — упорядоченная совокупность искусственных нейронов, выполняющая одновременное и идентичное преобразование входного векторного сигнала в выходной векторный сигнал [2].

Обучение искусственной нейронной сети — целенаправленная настройка параметров искусственной нейронной сети на основе анализа входных данных для достижения её требуемого поведения [2].

Цвет — набор интенсивностей, описывающий восприятие электромагнитного излучения в видимом диапазоне, каждая из которых соответствует отдельному каналу восприятия.

Цветовое пространство — множество всех возможных цветов с заданным количеством каналов восприятия.

Изображение — отображение, сопоставляющее каждой точке некоторого координатного пространства цвет в выбранном цветовом пространстве.

Непрерывное изображение — изображение, область определения которого является связным подмножеством многомерного пространства с неотрицательными вещественными координатами.

Дискретное (цифровое) изображение — изображение, область определения которого является конечным подмножеством многомерного пространства с неотрицательными целыми координатами.

Тензор дискретного изображения — многомерный массив неотрицательных вещественных чисел, размерность которого определяется количеством координатных направлений изображения и количеством каналов восприятия цвета. Элементы этого массива соответствуют значениям яркости для каждого канала в каждой дискретной точке изображения.

Обнаружение признаков генерации на изображении — процесс определения наличия признака генерации на цифровом изображении, заключающийся в вычислении апостериорной вероятности того, что изображение содержит такой признак, и в принятии бинарного решения на основе заданного порогового значения.

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

В настоящей расчетно-пояснительной записке применяют следующие сокращения и обозначения.

ИНС — искусственная нейронная сеть.

$\mathbb{Z}_+$ — множество неотрицательных целых чисел.

$\mathbb{R}_+$ — множество неотрицательных действительных чисел.

PSNR — Peak Signal-to-Noise Ratio, пиковое отношение сигнала к шуму.

ReLU — Rectified Linear Unit, линейный выпрямительный элемент.

GELU — Gaussian Error Linear Unit, линейный элемент Гауссовой ошибки.

IDEF0 — Integration Definition for Function Modeling, определения интеграций для функционального моделирования.

UML — Unified Modeling Language, единый язык моделирования.

C4 — «Context, Containers, Components, Code», «контекст, контейнеры, компоненты, код».

ВВЕДЕНИЕ

Распространение синтезированного контента, созданного с использованием технологий машинного обучения, приводит к увеличению числа правонарушений и экономическому ущербу [3]. Количество дел, связанных с применением искусственного интеллекта, в российских судах за последние пять лет возросло более чем на 40%. Визуальный анализ не позволяет достоверно идентифицировать значительную часть качественно исполненных поддельных изображений. Указанные обстоятельства обуславливают необходимость разработки автоматизированных методов обнаружения изображений-имитаторов.

Целью данной выпускной квалификационной работы является разработка метода обнаружения признаков генерации на изображении с использованием нейронной сети.

Для достижения поставленной цели необходимо выполнить следующие задачи:

- проанализировать предметную область;
- проанализировать известные нейросетевые решения;
- провести классификацию и сравнительный анализ рассмотренных решений;
- формализовать задачу в виде функциональной модели;
- спроектировать и разработать программное обеспечение для обнаружения признаков генерации на изображении;
- провести исследование работоспособности программной реализации предложенного метода.

1 Аналитический раздел

В данном разделе представлены анализ предметной области, анализ известных нейросетевых решений, классификация и сравнительный анализ рассмотренных решений, формализации изображения и задачи.

1.1 Анализ предметной области

Признак генерации – это опирающийся на технологии машинного обучения целенаправленно созданный атрибут медиапродукта (видео, фотографии, аудиозаписи). Изображение, содержащее признак генерации, называется *поддельным*, если имеющийся на нём достоверно установленный признак направлен на формирование у целевых аудиторий фальсифицированного образа социального субъекта с целью получения выгоды или нанесения ущерба. Такие изображения представляют серьезную угрозу для доверия к цифровому контенту [3].

В данном разделе представляется история возникновения поддельных изображений и применение методов обнаружения признаков генерации на изображении.

1.1.1 История возникновения поддельных изображений

Исследования в области автоматизированного синтеза визуального контента начались в конце 1990-х годов. В 1997 году была представлена программа «Video Rewrite», которая позволяла формировать видеоряд, где артикуляционная мимика лица соответствовала синтезированной аудиодорожке [4]. Эти разработки носили академический характер и были доступны ограниченному кругу специалистов. Эволюция технологий продолжилась в последующие два десятилетия, включая такие проекты, как использование цифрового аватара Одри Хепберн в рекламной кампании 2014 года и омоложение лиц актёров в кинематографе, например, в фильме «Ирландец» 2019 года [5][6]. В данный период синтез видеоконтента в значительной степени оставался процессом, контролируемым разработчиками.

Существенный прогресс в развитии технологии произошел в 2014 году с разработкой Яном Гудфеллоу программного метода генеративно-

состязательных ИНС [7]. Данный метод основан на использовании двух конкурирующих искусственных нейронных сетей: генератора, создающего синтетические данные, и дискриминатора, задачей которого является обнаружение сгенерированных образцов среди всего набора данных.

Широкое распространение поддельные изображения получили в 2017 году, когда пользователь платформы Reddit под псевдонимом «Deepfakes» опубликовал серию видеороликов с заменой лиц знаменитостей. Это событие продемонстрировало потенциал технологии глубокого обучения ИНС и вызвало значительный общественный резонанс [3].

1.1.2 Применение методов обнаружения признаков генерации на изображении

Методы обнаружения признаков генерации на изображении используются в следующих областях:

- верификация видеоматериалов и аудиозаписей государственными учреждениями и новостными агентствами для противодействия манипуляции общественным мнением и провоцированию социальной напряжённости [8][3];
- биометрическая аутентификация и предотвращение мошеннических операций [9][10][11];
- анализ цифровых доказательств для установления подлинности или факта модификации видеозаписей и фотографий, представляемых в судебном делопроизводстве [12][13];
- идентификация неправомерного использования изображений граждан в синтетическом контенте без их согласия [3];
- контроль целостности и установление авторства цифрового контента для защиты интеллектуальной собственности от несанкционированного использования [14].

1.2 Анализ известных нейросетевых решений

История развития искусственных нейронных сетей берет начало в середине 20-го века с создания упрощенных математических моделей биологиче-

ского нейрона – *искусственных нейронов*. Первой такой формальной моделью стала модель, предложенная Уорреном Мак-Каллоком и Уолтером Питтсом в 1943 году [1]. Данная модель представляет собой устройство с несколькими бинарными входами и одним бинарным выходом. Общая схема данной модели представлена на рисунке 1.1.




Рисунок 1.1 – Общая схема искусственного нейрона Мак-Каллока-Питтса [1]

Искусственный нейрон осуществляет вычисление взвешенной суммы $\sum_{i=1}^n x_i w_i + b$ входных сигналов, которая затем сравнивается с некоторым пороговым значением θ . Если сумма превышает порог, выход нейрона α принимает единичное значение, в противном случае – нулевое [15].

Искусственная нейронная сеть представляет собой совокупность взаимосвязанных искусственных нейронов. Связи между нейронами определяются системой весов, которые задают структуру сети и обеспечивают преобразование входного векторного сигнала в выходной. Упорядоченная совокупность искусственных нейронов, выполняющая одновременное и идентичное преобразование входного векторного сигнала в выходной сигнал называется *слоем*. ИНС может содержать неограниченное число слоёв [2].

Одним из первых формализованных принципов изменения весов связей между нейронами является правило Хэбба, предложенное в 1949 году [16]. Согласно данному принципу, изменение веса связи между двумя нейронами пропорционально произведению их активностей. Если возбуждение одного нейрона регулярно сопровождается возбуждением другого, вес связи между ними увеличивается.

Целенаправленная настройка параметров искусственной нейронной сети

на основе анализа входных данных для достижения требуемого поведения модели называется *обучением* [17].

1.2.1 Свёрточные нейронные сети

Свёрточные искусственные нейронные сети представляют собой разновидность многослойных ИНС, разработанную для обработки данных с сеточной структурой, таких как изображения. Данная архитектура была предложена Яном Лекуном в 1988 году и вдохновлена биологическими процессами человеческой зрительной системы [18].

Ключевой концепцией свёрточных сетей является использование операции *свёртки*, которая позволяет выявлять локальные пространственные зависимости в обрабатываемых данных [19].

Архитектура свёрточной нейронной сети включает следующие компоненты:

1. *Свёрточные слои* выполняют извлечение признаков путём применения набора обучаемых фильтров к входным данным. Каждый фильтр сканирует изображение, обнаруживая определённые паттерны [19];
2. *Подвыборочные слои* уменьшают размерность карт признаков, сохраняя наиболее значимую информацию. Это позволяет снизить вычислительную сложность [20];
3. *Полносвязные слои* завершают архитектуру сети, преобразуя извлечённые иерархические признаки в конечный результат [18][2].

Пример схемы свёрточной искусственной нейронной сети представлен на рисунке 1.2.




Рисунок 1.2 – Пример схемы свёрточной ИНС

Meso-4

Архитектура Meso-4 была разработана в 2018 году исследовательской группой под руководством Дариуса Афшара. Она предназначена для обнаружения дипфейков на изображениях лиц людей. Основная идея архитектуры заключается в анализе *мезоскопических свойств изображений* – промежуточного уровня между анализом цветов пикселей и их семантическим анализом [9].

Данная свёрточная ИНС состоит из последовательности четырёх блоков, каждый из которых включает свёрточные и подвыборочные слои. В свёрточных слоях используется пороговая функция активации под названием Rectified Linear Unit, имеющая следующий вид [21]:

$$ReLU(z) = \max(0, z) \quad (1.1)$$

Для улучшения обобщающей способности применяются операция *пакетной нормализации* [22] после каждого свёрточного слоя и операция *отключения нейронов* [23] в полносвязных слоях. Схема архитектуры Meso-4 представлена на рисунке 1.3.

Обучающие наборы данных и результаты подсчёта долей верно классифицированных изображений [9] представлены в таблицах Б.1 и 1.1 соответственно.

Основным преимуществом данной архитектуры является ее относительная компактность, включающая 27 977 параметров, что обеспечивает меньшие вычислительные затраты и возможность быстрого обучения на ограниченных ресурсах. К недостаткам можно отнести снижение точности при сжатии входных изображений [9].

Таблица 1.1 – Результаты тестирования Meso-4

Контрольный набор данных	Точность, %
Авторский набор данных	89.1
FaceForensics [12]	94.6




Рисунок 1.3 – Схема архитектуры Meso-4

MesoInception-4

Архитектура MesoInception-4, предложенная в 2018 году Дариусом Афшаром, представляет собой модификацию архитектуры Meso-4 [9]. Её ключевая особенность заключается в наличии *слоёв многомасштабной свёртки* [24] на начальных этапах сети.

Идея слоя многомасштабной свёртки заключается в применении параллельных операций свёртки с ядрами различного размера. Данное решение позволяет анализировать признаки изображения на разных уровнях детализации в рамках одного вычислительного блока. Схемы архитектуры данного слоя и архитектуры MesoInception-4 представлены на рисунках 1.4 и 1.5 соответственно.

Таблица 1.2 – Параметры слоёв многомасштабной свёртки архитектуры MesoInception-4

Номер слоя	A	B	C	D
1	1	4	4	1
2	1	4	4	2

Параметры слоёв многомасштабной свёртки, обучающие наборы данных и результаты подсчёта долей верно классифицированных изображений [9] представлены в таблицах 1.2, Б.1 и 1.3 соответственно.




Рисунок 1.4 – Схема архитектуры слоя многомасштабной свёртки, параметризуемой с помощью $A, B, C, D \in \mathbb{N}$

Главным преимуществом архитектуры MesoInception-4 является способность комбинировать признаки различного масштаба благодаря использованию слоёв многомасштабной свёртки, что привело к небольшому повышению точности по сравнению с Meso-4, при практически неизменной вычислительной сложности. Недостатком является чувствительность к сжатию входных изображений.

Таблица 1.3 – Результаты тестирования MesoInception-4

Контрольный набор данных	Точность, %
Авторский набор данных	91.7
FaceForensics	96.8




Рисунок 1.5 – Схема архитектуры MesoInception-4

1.2.2 Капсульные нейронные сети

Капсульные искусственные нейронные сети представляют собой архитектуру, предложенную в 2017 году Джеффри Хинтоном [25], целью которой является преодоление ограничений свёрточных ИНС в области инвариантности к пространственным преобразованиям и анализа иерархических отношений между частями объектов. Пример схемы капсульной ИНС представлен на рисунке 1.6.




Рисунок 1.6 – Пример схемы капсульной ИНС

Основной единицей данной архитектуры является *капсула* – группа нейронов, активность которых отражает вероятность обнаружения определённого

объекта или его части, а также его параметры, такие как положение, ориентация, масштаб и иные пространственные свойства. В отличие от скалярных выходов нейронов в свёрточных сетях или перцептронах, выход капсулы является вектором, длина которого определяет вероятность обнаружения объекта, а компоненты содержат значения его параметров. Пример схемы структуры капсулы представлена на рисунке 1.7.

Входные векторы Группа нейронов Выходной вектор




Рисунок 1.7 – Пример схемы структуры капсулы

Алгоритмом, обеспечивающим взаимодействие между капсулами, является алгоритм *динамической маршрутизации* [25], определяющий степень связи между капсулами смежных слоёв. Формально, выходной вектор капсулы вычисляется с помощью нелинейной *функции сжатия*, которая сохраняет ориентацию вектора и нормализует его длину:

$$\vec{v}_j = \frac{\|\vec{s}_j\|^2}{1 + \|\vec{s}_j\|^2} \cdot \frac{\vec{s}_j}{\|\vec{s}_j\|}, \quad (1.2)$$

где $\vec{s}_j$ – вектор выходных значений нейронов капсулы.

Архитектура капсульных сетей отличается от свёрточных сетей наличием капсульных слоёв, меньшим количеством или полным отсутствием подвыборочных слоёв и большей подверженности воздействию шумов на входных данных [25].

Capsule-Forensics

Капсульная сеть Capsule-Forensics была представлена в 2018 году авторами Х. Нгуеном, Джуничи Ямагиши и Исао Эчизеном [10]. Это одна из первых архитектур, применяющих капсульные сети для обнаружения дипфейков на изображениях.

Ключевая идея данной архитектуры заключается в использовании предобученных свёрточных слоёв сети VGG-19 [26] для извлечения признаков входных изображений и их последующей обработки капсульными слоями. Схема архитектуры Capsule-Forensics представлена на рисунке 1.8.




Рисунок 1.8 – Схема архитектуры Capsule-Forensics

Наличие капсульных слоёв позволяет данной сети лучше определять пространственные иерархии и отношения между частями изображения по сравнению со свёрточными сетями [25]. Недостатками можно считать относительно сложную архитектуру, вычислительную сложность алгоритма динамической маршрутизации, а также зависимость от предобученной модели VGG-19 [10].

В выходном полносвязном слое используется пороговая функция активации под названием Softmax, которая имеет следующий вид [27]:

$$\text{Softmax}(\vec{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}, \quad i = \overline{1, K}, \quad (1.3)$$

где

- $\vec{z} = (z_1, z_2, \dots, z_K)$ – входной вектор;
- K – количество параметров.

Обучающий набор данных рассматриваемой ИНС представлен в виде FaceForensics. Результаты тестирования представлены в таблице 1.4 [10].

Таблица 1.4 – Результаты тестирования Capsule-Forensics

Контрольный набор данных	Точность, %
FaceForensics	99.37

1.2.3 Трансформеры

Трансформеры представляют собой архитектуру искусственных нейронных сетей, предназначенную для обработки последовательностей данных. Данная архитектура была предложена в 2017 году коллективом авторов из Google Brain [28] и была применена в задаче обработки языка.

Особенностью трансформеров является использование *механизма внимания* [28], который позволяет оценивать взаимное влияние всех элементов последовательности данных друг на друга и представлять их в форме, учитывающей это влияние.




Рисунок 1.9 – Пример схемы трансформера

Пусть задана последовательность векторов $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n \in \mathbb{R}^d$, где $n \in \mathbb{N}$ – длина последовательности, $d \in \mathbb{N}$ – размерность векторного представления элемента. Для каждого элемента последовательности вычисляется следующий набор векторов [28]:

1. *Запрос* $\vec{q}_i$ – вектор, представляющий текущий элемент в роли «искателя» контекста от других элементов

$$\vec{q}_i = W^Q \vec{x}_i, \quad (1.4)$$

где W^Q – обучаемая матрица параметров запросов;

2. *Ключ* $\vec{k}_i$ – вектор, представляющий элемент в роли «источника» контекста для других элементов

$$\vec{k}_i = W^K \vec{x}_i, \quad (1.5)$$

где W^K – обучаемая матрица параметров ключей;

3. *Значение* $\vec{v}_i$ – вектор, содержащий фактическую информацию об элементе для агрегирования

$$\vec{v}_i = W^V \vec{x}_i, \quad (1.6)$$

где W^V – обучаемая матрица параметров значений.

Затем для каждого элемента $\vec{x}_i$ вычисляется степень его влияния на все остальные элементы последовательности. Для этого определяется скалярное произведение вектора запроса $\vec{q}_i$ на векторы ключей всех элементов $\vec{k}_j$ с последующим применением функции Softmax:

$$\alpha_{ij} = \frac{\exp\left(\frac{\vec{q}_i \cdot \vec{k}_j}{\sqrt{d}}\right)}{\sum_{m=1}^n \exp\left(\frac{\vec{q}_i \cdot \vec{k}_m}{\sqrt{d}}\right)}, \quad (1.7)$$

где $\alpha_{ij} \in [0, 1]$ – степень влияния элемента $\vec{x}_j$ на элемент $\vec{x}_i$.

Выходной вектор $\vec{z}_i$ для элемента $\vec{x}_i$, учитывающий влияние других

элементов, представляет собой взвешенную сумму векторов значений [28]:

$$\vec{z}_i = \sum_{j=1}^n \alpha_{ij} \vec{v}_j \quad (1.8)$$

В результате механизма внимания формируется новая последовательность контекстуализированных векторов $\vec{z}_1, \vec{z}_2, \dots, \vec{z}_n$. Каждый вектор $\vec{z}_i$ содержит информацию не только об исходном элементе $\vec{x}_i$, но и о всех элементах последовательности, с которыми он значимо взаимодействует [28].

Трансформер может быть адаптирован для работы с изображениями. Для этого изображение разбивается на непересекающиеся фрагменты фиксированного размера. Каждый фрагмент линейно преобразуется в векторное представление, после чего получается последовательность векторов $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$, где n – количество фрагментов. К этой последовательности применяется стандартный механизм работы трансформера [11].

К преимуществам обработки изображений трансформерами относятся восприятие глобального контекста за счёт механизма внимания и возможность параллельной обработки всех элементов последовательности. Недостатками являются квадратичная вычислительная сложность по отношению к количеству фрагментов и относительно большое количество параметров [28].

Vision Transformer

Архитектура Vision Transformer была представлена в 2020 году исследовательской командой Google Brain. Её ключевой особенностью является адаптация архитектуры трансформера к задаче компьютерного зрения [11].

Основная идея данной архитектуры заключается в разделении изображения на квадратные фрагменты 16×16 , последующем создании векторных представлений этих фрагментов и применении стандартного механизма работы для получившейся последовательности векторов. Векторным представлением фрагмента является набор из $16 \times 16 \times 3$ элементов, компоненты которого соответствуют интенсивностям пикселей фрагмента. Схема Vision Transformer представлена на рисунке 1.10.

Преимуществом данной архитектуры является высокая обобщающая способность. Недостатком же является относительно большая вычислительная сложность и количество параметров – 84 миллиона [11].




Рисунок 1.10 – Схема архитектуры Vision Transformer

В большинстве полносвязных слоёв архитектуры используется функция активации под названием Gaussian Error Linear Unit, имеющая следующий вид [29]:

$$GELU(x) = 0.5x \left(1 + \tanh \left[\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right] \right) \quad (1.9)$$

Обучающий набор данных рассматриваемой ИНС представлен в виде FaceForensics. Результаты тестирования представлены в таблице 1.5 [30].

Таблица 1.5 – Результаты тестирования Vision Transformer

Контрольный набор данных	Точность, %
FaceForensics	97.00

1.3 Классификация рассмотренных решений

В данном разделе представляются критерии и проведение классификации рассмотренных решений.

1.3.1 Критерии классификации

Выбор критериев классификации обусловлен необходимостью комплексной оценки методов обнаружения признаков генерации. Уровень декомпозиции изображения определяет подход к анализу визуальной информации, вычис-

лительная сложность характеризует практическую применимость метода, а устойчивость к шумам отражает его надёжность при работе с данными, подверженными искажениям. Критерии классификации и классы, соответствующие критериям представлены в таблицах 1.6-1.9.

Таблица 1.6 – Критерии классификации методов обнаружения признаков генерации на изображении

Критерий	Описание
Уровень декомпозиции изображения	Уровень признаков, на которых фокусируется метод при анализе изображения
Вычислительная сложность	Количество параметров метода
Устойчивость к шумам	Способность метода сохранять точность при работе с зашумлёнными изображениями

Таблица 1.7 – Классификация по уровню декомпозиции изображения

Класс	Описание
Микроскопические	Анализ на уровне интенсивностей пикселей
Мезоскопические	Анализ признаков промежуточного уровня между пикселями и семантическими объектами
Макроскопические	Анализ глобальных признаков, семантических связей и пространственных отношений между частями изображения
Холистические	Анализ изображения как целостной системы с учетом четырех взаимосвязей всех элементов и глобального контекста

Выбор количественных границ для классификации по вычислительной сложности обусловлен распределением параметров рассмотренных методов. Значение 500 тысяч определено как верхняя граница компактных архитектур, к которым относятся свёрточные сети с объёмом 28-30 тысяч параметров, пригодные для устройств с ограниченными ресурсами. Нижняя граница крупных методов установлена на 10 миллионов, поскольку трансформеры и капсуль-

Таблица 1.8 – Классификация по вычислительной сложности

Класс	Описание
Компактные	Количество параметров метода меньше 500 000
Средние	Количество параметров метода в интервале от 500 000 до 10 000 000
Крупные	Количество параметров метода больше 10 000 000

ные сети, обеспечивающие глобальный анализ, имеют от 70 до 80 миллионов параметров и выше.

Таблица 1.9 – Классификация по устойчивости к шумам

Класс	Описание
Неустойчивые	Методы, точность которых значительно снижается при работе с зашумлёнными изображениями
Устойчивые	Методы, точность которых незначительно снижается при работе с зашумлёнными изображениями

1.3.2 Результаты классификации

Результаты классификации обзореваемых решений по вышеописанным критериям представлены в таблице 1.10.

Таблица 1.10 – Классификация методов обнаружения признаков генерации на изображении

Метод	Уровень декомпозиции изображения	Вычислительная сложность	Устойчивость к шумам
Meso-4	Мезоскопические	Компактные	Неустойчивые
Meso Inception-4	Мезоскопические	Компактные	Устойчивые
Capsule Forensics	Макроскопические	Средние	Неустойчивые
Vision Transformer	Холистические	Крупные	Устойчивые

1.4 Сравнительный анализ рассмотренных решений

В данном разделе представляются критерии и проведение сравнения рассмотренных решений.

1.4.1 Критерии сравнения

Критерии сравнения представлены в таблице 1.11.

Таблица 1.11 – Критерии сравнения методов обнаружения признаков генерации

Критерий	Описание
Точность на наборе данных FaceForensics	Доля верно классифицированных изображений на наборе FaceForensics
Количество параметров	Количество параметров метода
Пороговое значение PSNR	Минимальное значение PSNR, при котором снижение точности метода не превышает 1%

1.4.2 Результаты сравнения

Результаты сравнительного анализа рассмотренных решений представлены в таблице 1.12.

Таблица 1.12 – Сравнительный анализ методов обнаружения признаков генерации

Метод	Точность на FaceForensics, %	Количество параметров, шт.	Пороговое значение PSNR, дБ.
Meso-4	94.6	27 997	30
Meso Inception-4	96.8	28 615	28
Capsule Forensics	99.37	2 800 000	34
Vision Transformer	97.0	84 000 000	24

Из результатов сравнительного анализа можно сделать вывод, что кап-

сульные ИНС демонстрируют наивысшую точность на незашумлённых изображениях, в то время как свёрточные ИНС демонстрируют относительно высокую точность на изображениях любого вида. Трансформеры обладают наибольшей устойчивостью к шуму, что обеспечивается наибольшим количеством параметров.

1.5 Формализация изображения

Цветом называется вектор $\vec{c}$, описывающий восприятие электромагнитного излучения в видимом диапазоне и характеризующийся набором интенсивностей, каждая из которых соответствует отдельному каналу восприятия:

$$\vec{c} = (c_0, c_1, \dots, c_{N-1}) \in \mathbb{R}_+^N, \quad (1.10)$$

где $N \in \mathbb{N}$ – количество каналов восприятия. Множество всех возможных цветов с N каналами восприятия называется *цветовым пространством* и обозначается $\mathbb{C}_N \subseteq \mathbb{R}_+^N$.

Изображением I называется отображение, сопоставляющее каждой точке некоторого координатного пространства $\Omega \subset \mathbb{R}_+^M$ цвет в выбранном цветовом пространстве $\mathbb{C}_N$:

$$I : \Omega \rightarrow \mathbb{C}_N \quad (1.11)$$

При этом выделяются следующие виды изображений:

- изображение называется *непрерывным*, если его область определения Ω является связным подмножеством $\mathbb{R}_+^M$;
- изображение называется *дискретным (цифровым)*, если его область определения Ω является конечным подмножеством $\mathbb{Z}_+^M$.

Тензором некоторого дискретного изображения I называется тензор $T^I \in \mathbb{R}_+^{L_1 \times L_2 \times \dots \times L_M \times N}$, элементы которого определяются следующим правилом:

$$T_{i_1, i_2, \dots, i_M, k}^I = I^{(k)}(i_1, i_2, \dots, i_M), \quad i_\mu = \overline{0, L_\mu - 1}, \quad k = \overline{0, N - 1} \quad (1.12)$$

где

- $I^{(k)}(i_1, \dots, i_M)$ – значение интенсивности сигнала k -го канала восприятия цвета в точке с координатами $(i_1, \dots, i_M)$;

- $L_\mu \in \mathbb{N}$ – размер изображения по μ -му координатному направлению;
- $N \in \mathbb{N}$ – количество каналов восприятия.

1.6 Формализация задачи

Пусть I является некоторым цифровым двумерным изображением, а событие $A = \{\text{изображение содержит признаки генерации}\}$. Функцией дискриминации F_τ называется следующая функция:

$$F_\tau(I) = \begin{cases} 1, & P(A | I) \geq \tau, \\ 0, & \text{иначе} \end{cases}, \quad (1.13)$$

где

- $\tau \in (0; 1)$ – пороговая вероятность;
- $P(A | I)$ – вероятность наличия признаков генерации на изображении I .

Возвращаемые значения функции дискриминации $F_\tau(I)$ отвечают следующему правилу:

$$\begin{cases} 1, & \text{изображение } I \text{ содержит признаки генерации} \\ 0, & \text{изображение } I \text{ не содержит признаки генерации} \end{cases} \quad (1.14)$$

При этом следует отметить, что наличие признаков генерации является необходимым, но не достаточным условием для отнесения изображения к категории «поддельных», так как подделка предполагает также целенаправленный характер фальсификации. Однако в рамках формализации задачи **допускается** интерпретация факта наличия признаков генерации на изображении как индикатора его поддельности, то есть возвращаемые значения функции дискриминации также понимаются следующим образом:

$$\begin{cases} 1, & \text{изображение } I \text{ является поддельным} \\ 0, & \text{изображение } I \text{ не является поддельным} \end{cases} \quad (1.15)$$

Задача обнаружения признаков генерации на изображении состоит в том, чтобы определить апостериорную вероятность $P(A | I)$. Функциональная постановка задачи представлена на рисунке 1.11.




Рисунок 1.11 – Функциональная постановка задачи обнаружения признаков генерации на изображении

1.7 Выводы из аналитического раздела

В результате проведенного анализа для реализации метода обнаружения признаков генерации на изображении с использованием нейронной сети были решены следующие задачи:

- проанализирована предметная область;
- проведен сравнительный анализ известных нейросетевых решений: сверточных ИНС, капсульных ИНС и трансформеров;
- предложены и обоснованы критерии классификации рассмотренных решений.

В результате проведенных классификации и сравнительного анализа было установлено, что:

- вычислительная сложность метода напрямую связана с уровнем декомпозиции изображения;
- капсульные ИНС достигают наибольшей точности на наборе FaceForensics, свёрточные ИНС обеспечивают баланс между точностью и устойчивостью к шуму, а трансформеры демонстрируют наибольшую устойчивость к искажениям данных, имея наибольшее количество параметров.

Предложена формализация задачи в виде функциональной модели, включающая определение апостериорной вероятности наличия признаков генерации и формальное задание функции дискриминации, что позволяет интерпретировать задачу обнаружения признаков генерации как задачу бинарной классификации.

2 Конструкторский раздел

В данном разделе представлены функциональная модель разрабатываемого метода, требования к разрабатываемому методу и программному обеспечению, а также описание их архитектур.

2.1 Функциональная модель разрабатываемого метода

Функциональная модель разрабатываемого метода, представлена на рисунке 2.1.



Рисунок 2.1 – Функциональная модель разрабатываемого метода обнаружения признаков генерации на изображении с использованием нейронной сети

2.2 Требования к разрабатываемому методу

Разрабатываемый метод должен отвечать следующими требованиям:

- точность метода на наборе данных FaceForensics должна составлять более 95%;
- количество параметров метода не должно превышать 10^8 ;
- метод должен относиться к классу «устойчивых».

2.3 Требования к разрабатываемому программному обеспечению

Разрабатываемое программное обеспечение должно обладать графическим интерфейсом, обеспечивающим пользователю возможность:

- загрузить изображение;
- получить значение апостериорной вероятности наличия признаков генерации на загруженном изображении;
- получить бинарное решение о наличии признаков генерации на загруженном изображении;
- получить значения апостериорной вероятности наличия признаков генерации на всех лицах людей на загруженном изображении;
- получить бинарное решение о наличии признаков генерации на всех лицах людей на загруженном изображении;
- изменить пороговую вероятность функции дискриминации.

2.4 Известные наборы необходимых размеченных данных

Обучение искусственной нейронной сети требует обучающего набора размеченных данных, содержащего как подлинные, так и синтезированные изображения. Далее представлены результаты анализа известных наборов необходимых размеченных данных.

2.4.1 FaceForensics

FaceForensics – набор данных, предложенный исследовательской группой из Технического университета Мюнхена. Данный набор предназначен для задач судебной экспертизы изображений и ориентирован на обнаружение манипуляций с лицом человека. Ключевой особенностью данного набора является его масштаб: он включает в себя более полумиллиона кадров, извлеченных из 1000 видео, полученных из открытых источников [12].



Рисунок 2.2 – Пример изменения изображений с использованием метода Face2Face

Формирование поддельных изображений в данном наборе данных выполняется с использованием метода замены лица Face2Face [31]. Данный метод позволяет перенести мимику и выражения лица человека из исходного видео на лицо человека из целевого видео в режиме реального времени. Пример изменения изображений с использованием данного метода представлен на рисунке 2.2.

Преимуществом набора является его значительный объём и использование единого метода подделки Face2Face. Недостатком является ограниченность одним типом подделки, снижающая обобщающую способность моделей.

2.4.2 FaceForensics++

FaceForensics++ представляет собой расширение набора данных FaceForensics, предложенное той же исследовательской группой под руководством А. Рёсслера. Набор данных включает почти 2 миллиона изображений, полученных из 1000 видео, отобранных из открытых источников [13].

Ключевым отличием FaceForensics++ от предшественника является расширение набора методов генерации поддельных изображений. Если оригинальный набор включал только поддельные изображения, созданные с помощью метода замены лица Face2Face, то в расширенной версии добавлены четыре новых подхода к изменению лица. Данные методы представлены в таблице 2.1.

Таблица 2.1 – Дополнительные методы генерации поддельных изображений в наборе данных FaceForensics++

Метод	Описание
Deepfakes [32]	Метод замены лица с использованием нейронной сети
FaceSwap [33]	Метод замены лица с использованием построения его трехмерной модели
FaceShifter [34]	Метод замены лица с использованием генеративно-состязательных нейронных сетей
NeuralTextures [35]	Метод замены лица с использованием генеративно-состязательных нейронных сетей

Преимуществом данного набора данных является разнообразие методов генерации подделок, повышающее репрезентативность данных для обучения моделей. Недостатком является значительный перекос по расовому и гендерному признаку [36].

2.5 Трансферное обучение нейронных сетей

Трансферное обучение представляет собой подход в машинном обучении, при котором знания, полученные моделью в процессе решения одной задачи, используются для повышения эффективности её обучения на другой, как правило, связанной задачи [37].

В контексте задач компьютерного зрения данный процесс можно разделить на два основных этапа:

- на этапе *предварительного обучения* модель учится решать вспомогательную задачу, получая возможность распознавать универсальные признаки;
- на этапе *донастройки* модель адаптируется для решения целевой задачи.

Преимуществом трансферного обучения является ускорение сходимости и повышение итоговой точности модели при ограниченном объеме целевой выборки. Недостатком может являться риск ухудшения итоговых результатов модели, если исходная и целевая задачи являются слабо связанными [37].

2.6 Ансамблирование нейронных сетей

Ансамблирование нейронных сетей представляет собой подход в машинном обучении, при котором выходные сигналы множества независимо обученных ИНС комбинируются для получения итогового решения. Принцип ансамблирования основывается на идее, что коллективное решение группы моделей в среднем оказывается точнее, чем решение отдельно взятого классификатора при условии, что ошибки этих моделей некоррелированы [38].

К преимуществам ансамблирования относятся повышение точности классификации по сравнению с использованием отдельной модели, увеличение устойчивости к шумам, а также снижение риска переобучения за счёт усреднения совокупности результатов нескольких классификаторов. Недостатками ансамблевого подхода являются пропорциональное увеличение вычислительной сложности и снижение интерпретируемости, так как итоговое решение формируется совокупностью внутренних представлений нескольких ИНС [38].

2.7 Архитектура разрабатываемой нейронной сети

Архитектура разрабатываемой нейронной сети представлена в виде ансамбля сверточной ИНС и трансформера.

2.7.1 Функциональная декомпозиция архитектуры

В результате сравнительного анализа, представленного в разделе 1.4, было установлено, что сверточные нейронные сети нацелены на выделение локальных текстурных признаков, в то время как трансформеры демонстрируют способность к анализу глобального контекста изображения. Кроме того, оба рассматриваемых класса нейронных сетей обладают устойчивостью к шуму.

Основная идея разрабатываемой архитектуры заключается в ансамблировании сверточной ИНС и трансформера, что позволит обеспечить итоговой модели как холистическое восприятие входного изображения, так и устойчи-

ВОСТЬ К ИСКАЖЕНИЯМ.




Рисунок 2.3 – Функциональная декомпозиция архитектуры разрабатываемой нейронной сети в виде нулевого уровня диаграммы IDEF0

Функциональная декомпозиция архитектуры разрабатываемой нейронной сети в виде нулевого и первого уровней диаграммы IDEF0 представлена на рисунках 2.3 и 2.4 соответственно.



Рисунок 2.4 – Функциональная декомпозиция архитектуры разрабатываемой нейронной сети в виде первого уровня диаграммы IDEF0

2.7.2 Формирование ансамбля нейронных сетей

Задача для трансферного обучения, формализованная в разделе 1.6, является семантически связанной с задачей распознавания образов, заключа-

ющейся в отнесении изображения к одному из заранее определенных классов [2]. Открытый набор размеченных данных ImageNet [39] предназначен для проверки пригодности моделей машинного обучения для решения задачи распознавания образов [40].

Схема архитектуры разрабатываемой нейронной сети представлена на рисунке 2.5.




Рисунок 2.5 – Схема архитектуры разрабатываемой нейронной сети

В качестве сверточной нейронной сети разрабатываемого ансамбля выбран EfficientNet [41] по следующим причинам:

- данная нейронная сеть является самой точной известной сверточной ИНС на наборе размеченных данных ImageNet [41];
- значения параметров данной предобученной на наборе размеченных данных ImageNet нейронной сети находятся в открытом доступе [42].

В качестве трансформера разрабатываемого ансамбля выбран Vision Transformer [11] по следующим причинам:

- данная нейронная сеть является одним из самых точных известных трансформеров на наборе размеченных данных ImageNet [11];

- значения параметров данной предобученной на наборе размеченных данных ImageNet нейронной сети находятся в открытом доступе [43].

2.7.3 Обучение разрабатываемой нейронной сети

В качестве набора данных для обучения разрабатываемой нейронной сети выбран FaceForensics++, содержащий 1000 подлинных и 5000 синтезированных видео с людьми. В обучающую выборку включены первые 24 кадра 1000 подлинных и 1000 синтезированных видео. Из каждого кадра предварительно извлекается лицо изображенного человека с помощью *алгоритма Виолы-Джонса* [44]. Структура обучающей выборки представлена в таблицах 2.2 и 2.3.

Таблица 2.2 – Разделение обучающей выборки разрабатываемой нейронной сети

Часть выборки	Количество видео, шт.	Количество изображений, шт.	Доля выборки, %
Тренировочная	1 800	43 200	90
Валидационная	200	4 800	10

Таблица 2.3 – Разделение методов FaceForensics++ в обучающей выборке разрабатываемой нейронной сети

Метод	Количество видео, шт.	Количество изображений, шт.	Доля выборки, %
Подлинный	1000	24 000	50
Face2Face	200	4 800	10
Deepfakes	200	4 800	10
FaceSwap	200	4 800	10
FaceShifter	200	4 800	10
NeuralTextures	200	4 800	10

В процессе обучения к изображениям применяются различные виды *аугментации* [45]:

- горизонтальное отражение;
- поворот на угол до 15 градусов;

- изменение яркости и контраста;
- нормализация.

Для ускорения работы алгоритма обратного распространения ошибки и защиты от переобучения используется *метод AdamW* [46]. В качестве функции ошибки алгоритма обучения выбрана *бинарная кросс-энтропия*, имеющая следующий вид:

$$l(x, y) = -[y \cdot \log(\sigma(x)) + (1 - y) \cdot \log(1 - \sigma(x))] \quad (2.1)$$

где

- x – предсказанное значение;
- y – истинное значение;
- $\sigma(x)$ – сигмоидная функция.

Схема алгоритма формирования обучающей выборки представлена на рисунке 2.6.




Рисунок 2.6 – Схема алгоритма формирования обучающей выборки

2.8 Архитектура разрабатываемого программного обеспечения

Архитектура разрабатываемого программного обеспечения организована в виде слоистой монолитной модели [47].

2.8.1 Функциональная декомпозиция архитектуры

Функциональная декомпозиция архитектуры разрабатываемого программного обеспечения в виде нулевого и первого уровней диаграммы IDEF0 представлена на рисунках 2.7 и 2.8 соответственно.




Рисунок 2.7 – Функциональная декомпозиция архитектуры разрабатываемого программного обеспечения в виде нулевого уровня диаграммы IDEF0




Рисунок 2.8 – Функциональная декомпозиция архитектуры разрабатываемого программного обеспечения в виде первого уровня диаграммы IDEF0

2.8.2 Контекст проектируемой архитектуры

Разрабатываемое программное обеспечение взаимодействует с пользователем, указывающим путь к изображению для проверки, и файловой системой, хранящей изображения и настройки используемой нейронной сети. Взаимодействие с разрабатываемым программным обеспечением происходит посредством графического интерфейса пользователя, который позволяет указать путь к изображению для проверки и отображает результат проведенного впоследствии анализа. Диаграмма контекста проектируемой архитектуры в нотации моделирования программных систем С4 [48] представлена на рисунке 2.9.



Рисунок 2.9 – Диаграмма контекста проектируемой архитектуры в нотации моделирования программных систем С4

Поток данных организован в соответствии с шаблоном проектирования Model-View-Presenter [49]: графический интерфейс пользователя передает команды контроллеру, который инициирует обработку команды сервисом бизнес-логики. Сервисы бизнес-логики отвечают за загрузку изображений из файловой системы, извлечение лиц из изображений и обнаружение признаков генерации на изображениях. Диаграмма потока данных проектируемой архитектуры представлена на рисунке 2.10.




Рисунок 2.10 – Диаграмма потока данных

2.8.3 Компоненты проектируемой архитектуры

Диаграмма контейнеров проектируемой архитектуры в нотации моделирования программных систем С4 представлена на рисунке 2.9.




Рисунок 2.11 – Диаграмма контейнеров проектируемой архитектуры в нотации моделирования программных систем С4

В рамках проектируемой системы выделены клиентская часть с графическим интерфейсом, серверная часть и файловое хранилище. В текущей реализации данные *контейнеры* [48] объединены в монолитное приложение. Однако выделение их в качестве самостоятельных логических единиц обеспечивает возможность последующего развертывания в виде распределенной системы без изменения глобальной логики.

Диаграмма компонентов на языке графического описания программных систем UML представлена на рисунке 2.12.

Рисунок 2.12 – Диаграмма компонентов проектируемой архитектуры на языке графического описания программных систем UML

Диаграмма классов на языке графического описания программных систем UML представлена на рисунке 2.13.




Рисунок 2.13 – Диаграмма классов проектируемой архитектуры на языке графического описания программных систем UML

Графический интерфейс пользователя разделен на панель управления, позволяющую загружать изображение и изменять настройки системы, и панель отображения, позволяющую производить предварительный просмотр загруженного изображения как целиком, так и отдельных содержащихся на нем лиц, а также демонстрирующей результаты проверки. Макет графического интерфейса проектируемого программного обеспечения представлен на рисунке 2.14.




Рисунок 2.14 – Макет графического интерфейса проектируемого программного обеспечения

2.9 Выводы из конструкторского раздела

В результате проектирования метода обнаружения признаков генерации на изображении с использованием нейронной сети были решены следующие задачи:

- сформирована функциональная модель разрабатываемого метода;
- сформированы требования к разрабатываемому методу;
- сформированы требования к разрабатываемому программному обеспечению;
- спроектирована архитектура разрабатываемой нейронной сети;
- спроектированы архитектура и графический интерфейс разрабатываемого программного обеспечения.

3 Технологический раздел

В данном разделе представляются выбор средств реализации, тестирование и демонстрация работы программного обеспечения, а также результаты обучения нейронной сети.

3.1 Выбор средств программной реализации

В качестве языка программирования для реализации программного обеспечения был выбран Python [50] по следующим причинам:

- поддержка объектно-ориентированной методологии проектирования;
- наличие в библиотеке языка PyTorch [51] необходимых классов предобученных искусственных нейронных сетей, выбранных по результатам проектирования;
- наличие в библиотеке языка OpenCV [52] необходимых функций реализации алгоритма Виолы-Джонса, выбранного по результатам проектирования.

3.2 Результаты обучения нейронной сети

Качество обучения нейронной сети для решения задачи бинарной классификации характеризуется набором количественных метрик, описываемых с помощью следующих терминов:

- *истинно положительное срабатывание* – событие, когда возвращаемое нейронной сетью значение является положительным и соответствует действительности;
- *истинно отрицательное срабатывание* – событие, когда возвращаемое нейронной сетью значение является отрицательным и соответствует действительности;
- *ложно положительное срабатывание* – событие, когда возвращаемое нейронной сетью значение является положительным и не соответствует действительности;

- *ложно отрицательное срабатывание* – событие, когда возвращаемое нейронной сетью значение является отрицательным и не соответствует действительности.

Точностью искусственной нейронной сети называется следующая метрика [53]:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad (3.1)$$

где

- TP – количество истинно положительных срабатываний;
- TN – количество ложно положительных срабатываний;
- FP – количество истинно отрицательных срабатываний;
- FN – количество ложно отрицательных срабатываний.

Полнотой искусственной нейронной сети называется следующая метрика [53]:

$$Recall = \frac{TP}{TP + FN}, \quad (3.2)$$

где

- TP – количество истинно положительных срабатываний;
- FN – количество ложно отрицательных срабатываний.

Данная метрика отражает долю верно определенных образцов положительного класса среди всех образцов положительного класса.

Сходимостью искусственной нейронной сети называется следующая метрика [53]:

$$Precision = \frac{TP}{TP + FP}, \quad (3.3)$$

где

- TP – количество истинно положительных срабатываний;
- FP – количество истинно отрицательных срабатываний.

Данная метрика отражает долю верно определенных образцов положительного класса среди всех образцов, отнесенных к этому классу.

F-мерой искусственной нейронной сети называется метрика равная среднему гармоническому между её полнотой и сходимостью [53]:

$$F\text{-score} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}, \quad (3.4)$$

— *Precision* – сходимость ИНС;

— *Recall* – полнота ИНС.

Данная метрика отражает способность искусственной нейронной сети достигать высоких полноты и сходимости.

Зависимости значений метрик обучения разработанной нейронной сети от эпохи представлены в таблицах Б.2 и 3.1.

Таблица 3.1 – Зависимости значений метрик качества обучения разработанной нейронной сети от эпохи

Эпоха	Потеря на тренировочной выборке	Потеря на валидационной выборке	Точность на тренировочной выборке, %	Точность на валидационной выборке, %
5	0.93616	0.93795	68.97	68.87
10	0.72180	0.72417	75.88	75.61
15	0.54823	0.55281	80.97	80.76
20	0.42918	0.42835	85.19	85.02
25	0.33418	0.33477	88.73	88.37
30	0.25464	0.25741	91.12	90.97
35	0.19737	0.20258	93.16	93.02
40	0.15842	0.16019	94.48	94.31
45	0.12447	0.12309	95.75	95.51
50	0.10512	0.09613	96.92	96.57
55	0.08707	0.09144	97.31	97.12
60	0.07671	0.07164	98.05	98.67
65	0.05816	0.05242	98.36	98.54

По таблице Б.2 были построены графики 3.1 и 3.2 зависимостей значений функции потерь и значений точности от эпохи соответственно.




Рисунок 3.1 – График зависимости значений функции потерь от эпохи




Рисунок 3.2 – График зависимости значений точности от эпохи

Результаты обучения разработанной нейронной сети представлены в таблицах 3.2 и 3.3.

Таблица 3.2 – Результаты обучения разработанной нейронной сети

Точность, %	Полнота, %	Сходимость, %	F-мера, %
98.67	98.65	98.65	98.65

Таблица 3.3 – Результаты обучения разработанной нейронной сети по классам

Класс	Полнота, %	Сходимость, %	F-мера, %
Подлинные изображения	98.50	98.79	98.65
Синтезированные изображения	98.79	98.50	98.65

Из полученных результатов, можно сделать вывод, что обучение модели характеризуется монотонным снижением значений функции потерь на тренировочной и валидационной выборках на всех эпохах без признаков переобучения. Достигнутые значения полноты и сходимости для обоих классов близки, что подтверждает сбалансированность классификации без смещения в сторону одного из типов изображений. Разработанная нейронная сеть отвечает предъявленным требованиям к точности и к вычислительной сложности, описанным в разделе 2.2.

3.3 Демонстрация работы программного обеспечения

Демонстрация работы разработанного программного обеспечения представлена на рисунке 3.3 и 3.4.




Рисунок 3.3 – Главное окно приложения

Главное окно приложения позволяет пользователю загрузить изображение для обнаружения признаков генерации и впоследствии демонстрирует ему результаты проверки как всего изображения в целом, так и отдельных обнаруженных на нем лиц. Панель управления дает возможность пользователю изменить значение пороговой вероятности функции дискриминации для формирования результирующего решения о поддельности изображения.




Рисунок 3.4 – Результаты обнаружения признаков генерации на изображениях с использованием разработанного программного обеспечения при значении пороговой вероятности равном 0.5

Из полученных результатов можно сделать вывод, что разработанное программное обеспечение соответствует спроектированной архитектуре и отвечает всем предъявленным требованиям, описанным в разделе 2.3. Исходный код приложения доступен в открытом сетевом репозитории [54].

3.4 Тестирование программного обеспечения

Были разработаны модульные и интеграционные тесты для методов классов, реализующих компоненты доступа к данным и бизнес-логики. Модульное тестирование выполнялось в соответствии с *лондонской моделью* [55], а интеграционное – с взаимодействием с файловой системой.

Сквозное тестирование разработанного программного обеспечения производилось в соответствии с сформированными классами эквивалентности, приведенными в таблице 3.4.

Таблица 3.4 – Классы эквивалентности сквозного тестирования разработанного программного обеспечения

Класс	Описание
Подлинные изображения	Изображения корректного формата, содержащие одно или несколько лиц и не имеющие признаки генерации
Поддельные изображения	Изображения корректного формата, содержащие одно или несколько лиц и имеющие признаки генерации
Изображения без лиц	Изображения корректного формата, не содержащие лица
Некорректный файл	Файлы с расширением или содержимым, отличным от ожидаемого
Граничные значения пороговой вероятности	Установка пороговой вероятности равной граничным значениям

Все проведенные тесты были успешно пройдены. Из результатов тестирования разработанного программного обеспечения можно сделать вывод, что оно корректно обрабатывает все выделенные классы эквивалентности. Успешное прохождение модульных и интеграционных тестов подтверждает надежность компонентов доступа к данным и бизнес-логики.

3.5 Выводы из технологического раздела

В результате реализации метода обнаружения признаков генерации на изображении с использованием нейронной сети были решены следующие задачи:

- реализована и обучена необходимая искусственная нейронная сеть;
- разработано и протестировано программное обеспечение, реализующее предложенный метод.

Результаты обучения нейронной сети и тестирование разработанного программного обеспечения показали соответствие метода всем предъявленным требованиям и его практическую применимость.

4 Исследовательский раздел

В данном разделе представляются постановка и проведение исследования разработанного метода.

4.1 Постановка исследования

Задачами проводимого исследования являются:

- определение качества разработанного метода на наборе данных FaceForensics;
- сравнение разработанного метода с рассмотренными решениями;
- классификация разработанного метода.

4.2 Проведение исследования

4.2.1 Качество разработанного метода на наборе данных FaceForensics

Качество разработанного метода на наборе данных FaceForensics было определено с использованием множества образцов, содержащего только изображения, созданные методом Face2Face. Данное множество образцов содержит 480 изображений только из набора данных FaceForensics и является подмножеством валидационной части обучающей выборки, описанной в разделе 2.7.3.

Результаты определения качества разработанного метода представлены в таблицах 4.1 и 4.2. По таблице 4.1 были построены матрица ошибок, представленная на рисунке 4.1.

Таблица 4.1 – Значения количества истинных и ложных срабатываний разработанного метода при определении качества на наборе данных FaceForensics

Количество истинно положительных срабатываний, шт.	Количество истинно отрицательных срабатываний, шт.	Количество ложно положительных срабатываний, шт.	Количество ложно отрицательных срабатываний, шт.
238	236	2	4

Таблица 4.2 – Результаты определения качества разработанного метода на наборе данных FaceForensics

Точность, %	Полнота, %	Сходимость, %	F-мера, %
98.75	98.35	99.17	98.76




Рисунок 4.1 – Матрица ошибок при определении качества разработанного метода на наборе данных FaceForensics

По полученным результатам оценки качества разработанного метода на наборе данных FaceForensics можно сделать вывод, что метод отвечает требованию к точности, предъявленному в разделе 2.2, имея значение точности 98.75%, и демонстрирует относительно высокую обобщающую способность на поддельных изображениях, полученных методом Face2Face.

4.2.2 Сравнение разработанного метода с рассмотренными решениями

Сравнение разработанного метода с рассмотренными решениями было проведено по критериям, представленным в таблице 1.11. Результаты сравнения разработанного метода с рассмотренными решениями представлены в таблице 4.3.

Таблица 4.3 – Сравнение разработанного метода с рассмотренными решениями

Метод	Точность на FaceForensics, %	Количество параметров, шт.	Пороговое значение PSNR, дБ.
Meso-4	94.6	27 997	30
Meso Inception-4	96.8	28 615	28
Capsule Forensics	99.37	2 800 000	34
Vision Transformer	97.0	84 000 000	24
Разработанный метод	98.75	91 300 000	24

Гистограмма значений точности разработанного метода и Capsule Forensics на сжатых изображениях набора данных FaceForensics




Рисунок 4.2 – Гистограмма значений точности разработанного метода и Capsule Forensics на сжатых изображениях набора данных FaceForensics [10]

Из полученных результатов можно сделать вывод, что разработанный метод обнаружения признаков генерации на изображении уступает Capsule Forensics по точности на незашумленных изображениях FaceForensics, однако превосходит остальные рассмотренные свёрточные и трансформерные архитектуры, при этом характеризуется наибольшим количеством параметров среди всех сравниваемых решений.

Сравнение разработанного метода с Capsule Forensics было произведено на множестве данных, описанном в разделе 4.2.1, предварительно обработанном алгоритмом сжатия JPEG [56] с параметром качества равным 23. Результаты сравнения точности разработанного метода с Capsule Forensics представлены на гистограмме значений точности, изображенной на рисунке 4.2.

Из полученных результатов можно сделать вывод, что разработанный метод превосходит Capsule Forensics на низкокачественных изображениях, обладая значением точности равным 97.93%, то есть имеет более высокую устойчивость к шумам.

4.2.3 Классификация разработанного метода

Классификация разработанного метода была проведена по критериям, представленным в таблице 1.6. Результаты классификации разработанного метода представлены в таблице 4.4.

Таблица 4.4 – Классификация методов обнаружения признаков генерации на изображении

Метод	Уровень декомпозиции изображения	Вычислительная сложность	Устойчивость к шумам
Meso-4	Мезоскопические	Компактные	Неустойчивые
Meso Inception-4	Мезоскопические	Компактные	Устойчивые
Capsule Forensics	Макроскопические	Средние	Неустойчивые
Vision Transformer	Холистические	Крупные	Устойчивые
Разработанный метод	Холистические	Крупные	Устойчивые

Из полученных результатов можно сделать вывод, что разработанный метод относится к классу «устойчивых» методов, что соответствует предъявленным требованиям.

4.3 Выводы из исследовательского раздела

В результате исследования разработанного метода обнаружения признаков генерации на изображении с использованием нейронной сети было установлено:

- разработанный метод превосходит по точности на наборе данных FaceForensics все рассмотренные решения за исключением Capsule Forensics, обладая значением точности равным 98.67%;
- разработанный метод превосходит по точности Capsule Forensics на низкокачественных изображениях набора данных FaceForensics, обладая значением точности равным 97.93%;
- разработанный метод относится к классу «устойчивых» методов и содержит не более 10^8 параметров.

Из полученных результатов следует, что разработанный метод отвечает всем предъявленным требованиям, сформированным в разделе 2.2.

ЗАКЛЮЧЕНИЕ

В результате выполнения выпускной квалификационной работы были разработаны метод обнаружения признаков генерации на изображении с использованием нейронной сети и его программная реализация.

Для достижения поставленной цели решены следующие задачи:

- проанализирована предметная область;
- проанализированы известные нейросетевые решения;
- проведены классификация и сравнительный анализ рассмотренных решений;
- формализована задача в виде функциональной модели;
- спроектировано, разработано и протестировано программное обеспечение для обнаружения признаков генерации на изображении;
- проведено исследование работоспособности программной реализации предложенного метода.

В результате проведённого исследования установлено, что предложенный метод отвечает всем предъявленным требованиям: он превосходит по точности работы с немодифицированными изображениями все рассмотренные решения, кроме Capsule Forensics, обладая значением точности равным 98.75% на наборе данных FaceForensics, и при этом превосходит Capsule Forensics по точности работы с низкокачественными изображениями, что является следствием его принадлежности к классу «устойчивых» методов.

Разработанный метод является подходящим в задачах, где критически важна максимальная точность при анализе изображений низкого качества, подверженных сжатию или иным видам зашумления. Применимость разработанного метода обусловлена повышенным требованием к точности и устойчивости при отсутствии ограничений вычислительной сложности.

Дальнейшее развитие метода характеризуется повышением его точности на незашумленных изображениях набора данных FaceForensics, обобщением входных данных метода до произвольных изображений, а также уменьшением его вычислительной сложности при сохранении точности и устойчивости к шумам.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Warren S. McCulloch, Walter Pitts*. A Logical Calculus of the Ideas Immanent in Nervous Activity / Chicago: University of Illinois, College of Medicine, Department of Psychiatry at the Illinois Neuropsychiatric Institute, University of Chicago. — 1943. — URL: <https://www.cs.cmu.edu/~epxing/Class/10715/reading/McCulloch.and.Pitts.pdf> (дата обращения: 25.10.2025).
2. *Rumelhart D. E.* Parallel distributed processing: explorations in the microstructure of cognition / Massachusetts: MIT Press. — 1986. — URL: <https://gwern.net/doc/ai/nn/1986-rumelhart-pdp-v1.pdf> (дата обращения: 26.10.2025).
3. *Воронин И. А., Гавра Д. П.* Дипфейки: современное понимание, подходы к определению, характеристики, проблемы и перспективы / Российская школа связей с общественностью. — 2024. — URL: <https://cyberleninka.ru/article/n/dipfeyki-sovremennoe-ponimanie-podhody-k-opredeleniyu-harakteristiki-problemy-i-perspektivy> (дата обращения: 11.10.2025).
4. *Bregler C.* Video Rewrite: Driving Visual Speech with Audio. — URL: <https://www2.eecs.berkeley.edu/Research/Projects/CS/vision/human/bregler-sig97.pdf> (дата обращения: 11.10.2025).
5. *Wolfe J.* Framestore Creates CG Audrey Hepburn for Galaxy. — 2013. — URL: <https://www.awn.com/print/news/framestore-creates-cg-audrey-hepburn-galaxy> (дата обращения: 23.03.2026).
6. Facial Capture / Industrial Light, Magic. — 2015. — URL: <https://www.ilm.com/facial-capture/> (дата обращения: 23.03.2026).
7. *Goodfellow I. J.* Generative Adversarial Nets / Department of Computer Science, Operations Research. University of Montreal. — 2015. — URL: https://proceedings.neurips.cc/paper_files/paper/2014/file/f033ed80deb0234979a61f95710dbe25-Paper.pdf (дата обращения: 11.10.2025).

8. *Chesney R.* Deep Fakes: A Looming Challenge for Privacy, Democracy, and National Security / University of Texas School of Law. — 2018. — URL: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3213954 (дата обращения: 23.03.2026).
9. *Afchar D.* MesoNet: a Compact Facial Video Forgery Detection Network. — 2018. — URL: <https://arxiv.org/pdf/1809.00888> (дата обращения: 16.11.2025).
10. *Nguyen H., Yamagishi J., Echizen I.* Capsule-Forensics: Using Capsule Networks to Detect Forged Images and Videos. — 2018. — URL: <https://arxiv.org/pdf/1810.11215> (дата обращения: 17.11.2025).
11. *Dosovitskiy A.* An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale / Google Brain. — 2020. — URL: <https://arxiv.org/pdf/2010.11929> (дата обращения: 21.11.2025).
12. *Rössler A.* FaceForensics dataset / Technical University of Munich. — 2018. — URL: <https://niessnerlab.org/papers/2018/z0faceforensics/faceforensics-large-scale.pdf> (дата обращения: 16.11.2025).
13. *Rössler A.* FaceForensics++: Learning to Detect Manipulated Facial Images / Technical University of Munich. — 2019. — URL: https://openaccess.thecvf.com/content_ICCV_2019/papers/Rössler_FaceForensics_Learning_to_Detect_Manipulated_Facial_Images_ICCV_2019_paper.pdf (дата обращения: 16.02.2026).
14. *Maray A. H.* Designing and Implementing a Fake Document Detection System Using Artificial Intelligence / Department of Technical Electronic, Communication. — 2025. — URL: <https://onlinelibrary.wiley.com/doi/epdf/10.1155/je/3902628> (дата обращения: 23.03.2026).
15. *П. Г. Круг.* Нейронные сети и нейрокомпьютеры: учебное пособие по курсу «Микропроцессоры». — Москва: МЭИ, 2002. — С. 176.
16. *D. O. Hebb.* The Organization of Behavior. — New York: Wiley, 1949. — С. 364.
17. *Фрэнк Розенблатт.* Принципы нейродинамики: Перцептроны и теория механизмов мозга. — Москва: Мир, 1965. — С. 480.

18. *Y. LeCun*. Backpropagation Applied to Handwritten Zip Code Recognition / Holmdel: AT&T Bell Laboratories. — 1988. — URL: <http://yann.lecun.com/exdb/publis/pdf/lecun-89e.pdf> (дата обращения: 15.11.2025).
19. *LeCun Y.* Gradient-Based Learning Applied to Document Recognition / Holmdel: AT&T Bell Laboratories. — 1998. — URL: http://vision.stanford.edu/cs598_spring07/papers/Lecun98.pdf (дата обращения: 23.03.2026).
20. *Gholamalizhad H.* Pooling Methods in Deep Neural Networks, a Review / Shahrood University of Technology. — 2020. — URL: <https://arxiv.org/pdf/2009.07485> (дата обращения: 23.03.2026).
21. *Agarap A. F.* Deep Learning using Rectified Linear Units / Cornell University. — 2018. — URL: <https://arxiv.org/pdf/1803.08375> (дата обращения: 23.03.2026).
22. *Ioffe S., Szegedy C.* Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift / Google Inc. — 2015. — URL: <https://arxiv.org/pdf/1502.03167> (дата обращения: 16.11.2025).
23. *Srivastava N.* Dropout: A Simple Way to Prevent Neural Networks from Overfitting / Canada: University of Toronto. — 2014. — URL: https://www.jmlr.org/papers/volume15/srivastava14a/srivastava14a.pdf?utm_content=buffer79b4 (дата обращения: 16.11.2025).
24. *Szegedy C.* Going deeper with convolutions / Google Inc. — 2014. — URL: <https://arxiv.org/pdf/1409.4842> (дата обращения: 16.11.2025).
25. *Hinton G. E.* Dynamic Routing Between Capsules / Google Brain. — 2017. — URL: <https://arxiv.org/pdf/1710.09829> (дата обращения: 17.11.2025).
26. *Simonyan K., Zisserman A.* Very Deep Convolutional Networks for Large-Scale Image Recognition / Oxford. — 2014. — URL: <https://arxiv.org/pdf/1409.1556> (дата обращения: 17.11.2025).
27. *Franke M.* The softmax function: properties, motivation, and interpretation / Stanford. — 2023. — URL: https://alpslab.stanford.edu/papers/FrankeDegen_submitted.pdf (дата обращения: 23.03.2026).
28. *Vaswani A.* Attention Is All You Need / Google Brain. — 2017. — URL: <https://arxiv.org/pdf/1706.03762> (дата обращения: 21.11.2025).

29. *Hendrycks D.* Gaussian Error Linear Units / University of California. — 2023. — URL: <https://arxiv.org/pdf/1606.08415> (дата обращения: 23.03.2026).
30. Deepfake detection using ViT / Google Brain. — 2020. — URL: <https://huggingface.co/ashish-001/deepfake-detection-using-ViT> (дата обращения: 21.11.2025).
31. *Thies J.* Face2Face: Real-time Face Capture and Reenactment of RGB Videos / University of Erlangen-Nuremberg. — 2016. — URL: <https://arxiv.org/pdf/2007.14808> (дата обращения: 16.02.2026).
32. Deepfakes Github. — URL: <https://github.com/deepfakes/faceswap> (дата обращения: 16.02.2026).
33. FaceSwap Github. — URL: <https://github.com/MarekKowalski/FaceSwap> (дата обращения: 16.02.2026).
34. *Li L.* FaceShifter: Towards High Fidelity And Occlusion Aware Face Swapping / Peking University. — 2020. — URL: <https://arxiv.org/pdf/1912.13457> (дата обращения: 28.02.2026).
35. *Thies J.* Deferred Neural Rendering: Image Synthesis using Neural Textures / Technical University of Munich. — 2019. — URL: <https://arxiv.org/pdf/1904.12356> (дата обращения: 16.02.2026).
36. *Trinh L.* An Examination of Fairness of AI Models for Deepfake Detection / Department of Computer Science University of Southern California. — 2024. — URL: <https://ar5iv.labs.arxiv.org/html/2105.00558> (дата обращения: 25.03.2026).
37. *Zhuang F.* A Comprehensive Survey on Transfer Learning. — 2019. — URL: <https://arxiv.org/pdf/1911.02685v2> (дата обращения: 21.02.2026).
38. *Mohammed A.* A comprehensive review on ensemble deep learning: Opportunities and challenges / Department of Computer Science, Faculty of Graduate Studies for Statistical Research, Cairo University, Cairo, Egypt. — 2023. — URL: <https://www.sciencedirect.com/science/article/pii/S1319157823000228> (дата обращения: 21.02.2026).

39. *Deng J.* ImageNet: A large-scale hierarchical image database / Princeton University. — 2009. — URL: <https://ieeexplore.ieee.org/document/5206848> (дата обращения: 22.02.2026).
40. *Deng J.* ImageNet Large Scale Visual Recognition Challenge / Princeton University. — 2010. — URL: <https://arxiv.org/pdf/1409.0575> (дата обращения: 22.02.2026).
41. *Tan M.* EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks / Google. — 2019. — URL: <https://arxiv.org/abs/1905.11946> (дата обращения: 22.02.2026).
42. EfficientNet weights. — URL: <https://huggingface.co/google/efficientnet-b0> (дата обращения: 22.02.2026).
43. ViT weights. — URL: <https://huggingface.co/google/vit-base-patch16-224-in21k> (дата обращения: 22.02.2026).
44. *Wang Y.-Q.* An Analysis of the Viola-Jones Face Detection Algorithm / CMLA. — 2014. — URL: https://www.ipol.im/pub/art/2014/104/article_lr.pdf (дата обращения: 28.02.2026).
45. *Kumar T.* Image Data Augmentation Approaches: A Comprehensive Survey and Future directions / Dublin City University. — 2023. — URL: <https://arxiv.org/pdf/2301.02830> (дата обращения: 26.02.2026).
46. *Loshchilov I.* Decoupled Weight Decay Regularization / University of Freiburg. — 2019. — URL: <https://arxiv.org/pdf/1711.05101> (дата обращения: 28.02.2026).
47. *Мартин Р.* Чистая архитектура. Искусство разработки программного обеспечения. — Питер, 2022. — С. 352.
48. Документация по нотации моделирования архитектуры программных систем C4. — URL: <https://c4model.com/> (дата обращения: 28.02.2026).
49. *Гамма Э.* Паттерны объектно-ориентированного проектирования. — Питер, 2022. — С. 448.
50. Python documentation. — URL: <https://docs.python.org/3.10/> (дата обращения: 25.03.2026).

51. PyTorch documentation. — URL: <https://docs.pytorch.org/docs/stable/index.html> (дата обращения: 25.03.2026).
52. OpenCV documentation. — URL: <https://docs.opencv.org/4.x/> (дата обращения: 25.03.2026).
53. *Reddi V. J.* Introduction to Machine Learning. — Harvard University, 2025. — С. 2487.
54. Исходный код приложения. — URL: <https://github.com/Kori-Tamashi/bmstu/tree/diplomas/diplomas/bachelor/src> (дата обращения: 27.03.2026).
55. *Жаров С. В.* Конспект лекций по курсу «Тестирование и отладка программного обеспечения». — МГТУ им. Баумана, 2025. — С. 16.
56. *Raid A. M.* Jpeg Image Compression Using Discrete Cosine Transform / Mansoura University. — 2014. — URL: <https://arxiv.org/pdf/1405.6147> (дата обращения: 06.04.2026).

ПРИЛОЖЕНИЕ А

Презентация к выпускной квалификационной работе, содержащая n слайдов

ПРИЛОЖЕНИЕ Б

Таблицы к выпускной квалификационной работе

Таблица Б.1 – Обучающие наборы данных Meso-4 и MesoInception-4

Название	Описание	Изображения, содержащие признаки генерации, шт.	Изображения, не содержащие признаки генерации, шт.
Авторский набор данных	Авторский набор данных с синтетическими лицами, созданными методами глубокого обучения	5 111	7 250
FaceForensics [12]	Набор данных для обнаружения модификаций лиц методом Face2Face	4 500	4 500

Таблица Б.2 – Зависимости значений метрик качества обучения разработанной нейронной сети от эпохи

Эпоха	Потеря на тренировоч- ной выборке	Потеря на валидацион- ной выборке	Точность на тренировоч- ной выборке, %	Точность на валидацион- ной выборке, %
1	1.16655	1.15705	61.86	61.69
2	1.10617	1.10971	63.96	63.84
3	1.04500	1.03559	65.46	65.21
4	0.98615	0.98013	67.31	67.05
5	0.93616	0.93795	68.97	68.87
6	0.89290	0.89686	70.30	70.16
7	0.84794	0.84468	71.65	71.52
8	0.80289	0.80497	73.31	72.99
9	0.75820	0.76766	74.45	74.18
10	0.72180	0.72417	75.88	75.61
11	0.68334	0.67426	76.81	76.63
12	0.64190	0.63655	77.89	77.71
13	0.61416	0.61146	79.07	78.90
14	0.57898	0.58771	80.20	79.91
15	0.54823	0.55281	80.97	80.76
16	0.52823	0.53103	82.05	81.74
17	0.50010	0.50562	82.80	82.69
18	0.46961	0.46496	83.62	83.24
19	0.45136	0.44766	84.59	84.37
20	0.42918	0.42835	85.19	85.02
21	0.40430	0.39955	86.04	85.67
22	0.38248	0.37687	86.88	86.63
23	0.36030	0.35124	87.18	86.89
24	0.34924	0.34768	87.78	87.56
25	0.33418	0.33477	88.73	88.37
26	0.30817	0.31258	89.17	88.91
27	0.29542	0.29824	89.48	89.25
28	0.28282	0.29190	90.29	90.11
29	0.26960	0.26318	90.78	90.42
30	0.25464	0.25741	91.12	90.97
31	0.24703	0.24782	91.62	91.36
32	0.22782	0.22430	91.73	91.35
33	0.22564	0.23228	92.24	92.12
34	0.21527	0.22421	92.53	92.28
35	0.19737	0.20258	93.16	93.02

36	0.19216	0.19315	93.29	92.93
37	0.18286	0.17709	93.73	93.41
38	0.17234	0.16857	94.22	93.92
39	0.16685	0.16720	94.16	93.99
40	0.15842	0.16019	94.48	94.31
41	0.14872	0.15135	94.74	94.37
42	0.14996	0.14138	95.00	94.70
43	0.13722	0.12987	95.52	95.24
44	0.13386	0.13955	95.69	95.53
45	0.12447	0.12309	95.75	95.51
46	0.12547	0.12894	96.18	96.05
47	0.11717	0.11396	96.33	96.16
48	0.11028	0.10925	96.34	96.16
49	0.10637	0.11484	96.53	96.17
50	0.10512	0.09613	96.92	96.57
51	0.10527	0.11380	97.02	96.87
52	0.09662	0.09090	96.99	96.87
53	0.09195	0.10165	97.08	96.75
54	0.08929	0.08775	97.50	97.10
55	0.08707	0.09144	97.31	97.12
56	0.08815	0.08973	97.58	97.26
57	0.07614	0.07783	97.69	97.33
58	0.07441	0.08363	97.63	97.48
59	0.07620	0.07971	97.80	97.67
60	0.07671	0.07164	98.05	98.67
61	0.06969	0.07136	98.12	98.54
62	0.06535	0.06967	98.09	98.54
63	0.06795	0.06395	98.21	98.61
64	0.06000	0.05917	98.57	98.64
65	0.05816	0.05242	98.36	98.54